

ADQUISICIÓN Y TRANSMISIÓN DE DATOS

Grado en Ciencia de Datos

Trabajo Final

Marc Menéndez Zaragozà y Damià Puigcerver



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA

Motivación y Objetivos

Este proyecto tiene como motivación principal el estudio del impacto de distintas condiciones sociales y geográficas en el rendimiento de los atletas españoles de élite, dado nuestro interés en el deporte olímpico rey. Más concretamente, nuestro proyecto se centra en el análisis sobre la prueba de velocidad de los 100 metros lisos, a nivel absoluto y masculino.

El proyecto consta de dos vertientes clave, las cuales se centran en determinar la existencia del impacto de, por una parte, la altura de las ciudades donde se llevan a cabo las pruebas, y, por otro lado, el poder adquisitivo medio de las comunidades autónomas en las que viven los atletas, sobre el rendimiento de éstos en dichas pruebas, medido por las marcas o tiempos que consiguen en ellas.

Implementación

Para llevar a cabo el proyecto, hemos realizado un proceso de obtención de datos mediante las herramientas de Web Scraping vistas en clase, es decir, las librerías de Python, Requests, BeautifulSoup y Selenium.

En primer lugar, accedimos a la web <https://atletismorfea.es/> para obtener una serie de datos, para después organizarlos en diccionarios, con el fin de utilizar esta información en las siguientes páginas webs que consultaremos. En concreto, obtuvimos, para cada atleta participante en la modalidad elegida, su ranking, marca, viento durante la prueba, club, fecha de nacimiento, país, federación a la que pertenece, así como la posición, ciudad y fecha donde se realizó la prueba. Además, también generamos un diccionario cuyas claves son las comunidades autónomas, asociándoles una lista con todas las marcas de los atletas de esa comunidad; y otro con el mismo formato, pero para cada una de las ciudades de los 500 mejores atletas del ranking.

En segundo lugar, visitamos la página web del Instituto Nacional de Estadística (INE), <https://www.ine.es/>, donde accedimos al documento que especificaba la renta media, medida por el Producto Interior Bruto (PIB), asociada a cada comunidad autónoma, para lo cual tuvimos que normalizar mediante una función los nombres de las comunidades de la página anterior, donde, en vez de contener el nombre, constaban de un código de tres letras. Como resultado, se generó un nuevo diccionario, que modifica el anterior de las comunidades, de modo que, en vez de contener como valores solo una lista con las marcas, esto se actualizaba a una tupla formada por esta lista y la renta media.

A continuación, consultamos la página web <https://coordinates-converter.com/es/altimetro>, donde, para cada una de las ciudades obtenidas a partir de la primera página web, obtuvimos además su altura sobre el nivel del mar, actualizando el diccionario de ciudades de la misma forma que hicimos con el de comunidades, es decir, asociando una tupla con la lista de marcas y la altura como valores.

Para consultar toda esta información, se puede acceder al siguiente repositorio de GitHub: <https://github.com/damiapuigcerver6-stack/PROYECTO>, donde se encuentran todos los códigos

utilizados durante la implementación del proyecto. En concreto, encontramos un archivo con todas las funciones necesarias, junto al archivo de código que contiene la ejecución principal.

Filtrado y Sockets

Como apartados adicionales del proyecto, se ha realizado, por un lado, un proceso de filtrado de datos del fichero de excel de la información de los atletas a partir de la herramienta OpenRefine vista en las clases de prácticas, de manera que hemos normalizado la columna de los rankings de los atletas mediante las siguientes opciones: “Edit cells - Transform - if(value==”-”,null,value)” y “Edit cells - Fill down”. Además, se han renombrado las columnas del archivo y, para la columna “Resultado”, se han aplicado las opciones siguientes: “Edit cells - Transform - value.match(/(\d+).*/)[0]” y “Edit cells - Common Transforms - To number”.

Por otro lado, se ha implementado unos códigos de cliente TCP y servidor TCP, de modo que el servidor almacena información de los atletas, ciudades y comunidades, para poder proporcionársela al cliente, que puede realizar una solicitud sobre cualquiera de las tres categorías, eligiendo la opción que desee de cada una de ellas.

En el enlace al repositorio proporcionado en el apartado anterior, también encontramos los códigos de servidor y cliente, así como el archivo excel anterior y posterior al filtrado realizado tras los pasos seguidos en OpenRefine.

Resultados

Como resultado tras la realización del proyecto, hemos calculado el coeficiente de correlación de Pearson (r), que cuantifica la relación lineal existente entre el poder adquisitivo de las comunidades y las marcas de tiempo, así como entre la altura de las ciudades donde se realizaban las pruebas y estos tiempos. Para su visualización, hemos creado dos gráficos de dispersión (los cuales se mostrarán durante la presentación) con una línea de regresión, que intenta resumir la tendencia general de los datos.

Hemos visto que el r de Pearson entre la riqueza y las marcas de tiempo es de -0.3229, indicando una correlación negativa entre débil y moderada, lo cual implica que existe una leve tendencia inversa, es decir, que a medida que la riqueza media de la comunidad aumenta, las marcas de tiempo de dicha comunidad son menores, es decir, los atletas presentan un mejor resultado. La riqueza tiende a disminuir ligeramente. Al estar cerca de -0.3, la relación es perceptible pero no es especialmente fuerte.

Por último, el r de Pearson asociado a la relación entre altura y marcas es de 0.0676, lo cual indica una correlación positiva prácticamente nula, muy próximo a cero, por lo que no existe una relación lineal significativa entre la altura a la que se encuentra la ciudad donde se realiza la prueba y el resultados de los atletas que compiten en ella.